

四川大学高等教育自学考试

实践报告

题目三 Hadoop 平台搭建与 WordCount

专业 【请填写专业名称及专业代码】

层次 本科

课程代码 14899

课程名称 大数据技术基础（实践）

准考证号 【请填写准考证号】

考生姓名 【请填写姓名】

学历教育办公室制

二〇二六年九月

考生诚信承诺书

本人郑重承诺：本次课程实践考核报告，由本人在理解考核要求的基础上独立完成。报告中所涉及的实践过程、数据和分析结论均应由本人复核并确认真实有效。本人提交前将逐项检查代码、日志、截图和文字内容，并能够在抽查答辩中解释其实现原理与操作过程。

如有违反以上承诺，愿承担包括但不限于考核成绩作废、纪律处分等一切责任。

承诺人：_____

日期：_____年____月____日

提交前必须由考生本人核对内容并亲笔签署。

目录

- 1 实践题目与开发环境
- 2 环境准备
- 3 Hadoop 安装与配置
- 4 Hadoop 启动与验证
- 5 HDFS 操作
- 6 MapReduce WordCount 运行
- 7 运行结果汇总
- 8 实践问题及解决方法
- 9 实践总结
- 10 参考资料
- 11 提交前检查

1 实践题目与开发环境


所选题目：题目三 Hadoop 平台搭建与 MapReduce 示例运行。实践完成 HDFS 单节点服务配置、NameNode 和 DataNode 启动、HDFS 文件操作，以及 Hadoop 自带 WordCount 示例的实际执行和结果统计。

项目	实际环境
主机操作系统	macOS 26.6.2, Unix 命令行环境
Hadoop 版本	Apache Hadoop 3.5.0
JDK 版本	OpenJDK 17.0.20.1
HDFS 模式	单节点伪分布式，副本数 1
MapReduce 模式	local 本地执行模式
HDFS 地址	hdfs://localhost:9000
NameNode Web	http://localhost:9870

说明：本次实操在 macOS 的 Unix 环境真实完成，而考核模板建议 Ubuntu 或 CentOS。Hadoop、HDFS 和 MapReduce 命令及配置文件保持一致；如考点严格限定 Linux，可按 README 在 Linux 复现并替换图 1。

2 环境准备


通过 Homebrew 安装 Hadoop 3.5.0，其依赖提供 OpenJDK 17。运行脚本显式设置 JAVA_HOME、HADOOP_HOME、HADOOP_CONF_DIR 和 PATH，避免系统其他 JDK 版本影响 Hadoop。

A terminal window titled 'Hadoop - 01 linux java' showing the output of 'sw_vers' and 'java -version' commands. The 'sw_vers' command shows the system is macOS 26.6.2 on a 25G83 build. The 'java -version' command shows OpenJDK 17.0.20.1 installed via Homebrew.

```
$ sw_vers
ProductName: macOS
ProductVersion: 26.6.2
BuildVersion: 25G83

$ java -version
openjdk version "17.0.20.1" 2026-08-18
OpenJDK Runtime Environment Homebrew (build 17.0.20.1+0)
OpenJDK 64-Bit Server VM Homebrew (build 17.0.20.1+0, mixed mode, sharing)
```

图 1 操作系统与 JDK 版本验证

A terminal window titled 'Hadoop - 02 hadoop version' showing the output of 'hadoop version' and 'echo \$HADOOP_HOME' commands. The 'hadoop version' command shows Hadoop 3.5.0 installed via Homebrew. The 'echo \$HADOOP_HOME' command shows the installation path as /opt/homebrew/opt/hadoop/libexec.

```
$ hadoop version
Hadoop 3.5.0
Source code repository https://github.com/apache/hadoop.git
Compiled with protoc 3.25.6
This command was run using /opt/homebrew/Cellar/hadoop/3.5.0/libexec/share/hadoop/common/hadoop-common-3.5.0.jar

$ echo $HADOOP_HOME
/opt/homebrew/opt/hadoop/libexec
```

图 2 Hadoop 安装目录与版本验证

3 Hadoop 安装与配置

core-site.xml 将默认文件系统指向本机 NameNode 的 9000 端口；hdfs-site.xml 将副本数设为 1，并把 NameNode、DataNode 数据目录限定到本实践专用目录；mapred-site.xml 使用 local 模式运行 MapReduce，便于在单机环境观察 map、shuffle 和 reduce 流程。

```
Hadoop - 03 configuration

$ cat conf/core-site.xml
<configuration>
<property>
  <name>fs.defaultFS</name>
  <value>hdfs://localhost:9000</value>
</property>
</configuration>

$ cat conf/hdfs-site.xml
<configuration>
<property>
  <name>dfs.replication</name>
  <value>1</value>
</property>
</configuration>

$ cat conf/mapred-site.xml
<configuration>
<property>
  <name>mapreduce.framework.name</name>
  <value>local</value>
</property>
</configuration>
```

图 3 Hadoop 核心配置文件

4 Hadoop 启动与验证

首次运行通过 `hdfs namenode -format -force -nonInteractive` 格式化专用 NameNode；随后分别启动 NameNode 和 DataNode。脚本等待安全模式退出后再执行写操作，避免刚启动时删除或上传失败。jps 显示两个 HDFS Java 进程，dfsadmin 报告显示 1 个存活 DataNode。

```
Hadoop - 04 processes

$ jps
NameNode
DataNode
Jps

$ hdfs dfsadmin -report | head
Configured Capacity: 994662584320 (926.35 GB)
Present Capacity: 559954432968 (521.50 GB)
DFS Remaining: 559954391040 (521.50 GB)
Live datanodes (1):
```

图 4 Hadoop 进程与 HDFS 容量验证




图 5 NameNode Web 管理界面

5 HDFS 操作

在 /user/student_demo 下创建 input 目录，上传三个输入文件，并用 ls 与 cat 验证文件数量和内容。运行脚本还会创建 output、下载 part-r-00000，并在重复执行前删除本项目自己的旧 input 和 output，从而保持幂等。正式提交前可通过 STUDENT_ID=准考证号 将个人目录替换为要求的 /user/准考证号。



图 6 创建 HDFS 目录并上传三个文件


```
Hadoop - 06 input content

$ hdfs dfs -cat /user/student_demo/input/article1.txt
hadoop stores large data across machines
hadoop mapreduce processes data in parallel
wordcount is a classic mapreduce example
data becomes useful through reliable processing

$ wc -l input/*.txt
4 input/article1.txt
4 input/article2.txt
4 input/article3.txt
12 total
```

图 7 查看 HDFS 文件内容和本地行数

6 MapReduce WordCount 运行

项目自动查找 `hadoop-mapreduce-examples-3.5.0.jar`，并以 `wordcount` 作为示例类执行。三个输入文件对应三个 map split；Mapper 共输出 73 条键值记录，Combiner 在本地预聚合，Reducer 接收 46 个不同键并输出 46 行。日志中 map 和 reduce 均达到 100%，作业状态为 `completed successfully`，Failed Shuffles 为 0。

```
Hadoop - 07 wordcount job

$ hadoop jar hadoop-mapreduce-examples-3.5.0.jar wordcount input output
Total input files to process : 3
number of splits:3
Running job: job_local177670699_0001
map 100% reduce 100%
Job job_local177670699_0001 completed successfully
Map input records=12
Map output records=73
Reduce input groups=46
Reduce output records=46
Failed Shuffles=0
```

图 8 WordCount 作业命令、计数器与成功状态

```
Hadoop - 08 result

$ hdfs dfs -cat /user/student_demo/output/part-r-00000
a      1
across 2
and    2
available 1
data   8
hadoop 4
hdfs   3
in     3
mapreduce 5
processing 2
reliable 2
stores  2
tasks   2
wordcount 2
... 共 46 个不同单词
```

图 9 HDFS 输出文件 part-r-00000 内容

```
Hadoop - 09 summary top5

$ awk '{sum += $2} END {print sum}' result/part-r-00000
73
$ awk 'END {print NR}' result/part-r-00000
46
$ sort -k2,2nr -k1,1 result/part-r-00000 | head -5
data      8
mapreduce 5
hadoop    4
hdfs      3
in        3

WORDCOUNT_VERIFY=PASS
```

图 10 单词总数、不同单词数与 Top 5

7 运行结果汇总

序号	操作	命令或对象	实际结果
1	验证版本	hadoop version	Hadoop 3.5.0
2	启动 HDFS	hdfs --daemon start	NameNode、 DataNode 存活
3	创建目录	hdfs dfs -mkdir -p	/user/ student_demo/ input

序号	操作	命令或对象	实际结果
4	上传文件	hdfs dfs -put	3 个文件，共 12 行
5	运行 WordCount	hadoop jar ... wordcount	map 100%, reduce 100%
6	查看结果	hdfs dfs -cat	46 个不同单词
7	汇总词数	awk	总词数 73
8	Top 5	sort -k2,2nr	data 8, mapreduce 5, hadoop 4, hdfs 3, in 3
9	下载结果	hdfs dfs -get -f	downloaded- part-r-00000 已 生成

8 实践问题及解决方法

8.1 JDK 版本继承错误

系统原有 JAVA_HOME 指向 JDK 25，首次环境日志因此显示了非预期版本。解决方法是不再直接继承 JAVA_HOME，而让运行脚本默认固定到 Hadoop 3.5.0 的 Homebrew 依赖 JDK 17，并保留 HADOOP_JAVA_HOME 作为显式覆盖入口。重新运行后日志确认 OpenJDK 17.0.20.1。

8.2 NameNode 安全模式导致清理失败

NameNode 重启后处于安全模式扩展期，此时 rm 无法删除旧 input/output，后续 put 报 File exists。脚本增加 hdfs dfsadmin -safemode wait，确认安全模式退出后再清理旧目录，使同一流程可以重复执行。

8.3 命令警告污染结果文件

macOS 没有 Hadoop 本机原生库，hdfs dfs -cat 会输出 NativeCodeLoader 警告，直接通过管道保存可能污染 part-r-00000。解决方法是先用 hdfs dfs -get 下载 HDFS 原始文件，再从下载文件复制和统计。最终 part-r-00000 仅包含 46 行“单词-次数”数据。

9 实践总结

本次实践完成了从 Hadoop 环境配置、HDFS 服务启动、输入数据上传到 MapReduce WordCount 处理和结果分析的完整流程。我通过 core-site.xml 理解

客户端如何定位 NameNode，通过 hdfs-site.xml 设置单节点副本策略，并从 jps、dfsadmin 和 Web 页面三个角度确认集群状态。WordCount 的计数器把处理过程量化为 3 个输入分片、12 条输入记录、73 条 Map 输出和 46 条 Reduce 输出，使 Mapper、Combiner、Shuffle 与 Reducer 的职责更直观。实际排错还说明环境变量、安全模式和标准输出处理会直接影响可重复性。当前实践仅使用一个 DataNode，不能体现跨节点容错和网络传输；后续可在多台 Linux 虚拟机上部署全分布式集群，并增加 YARN、资源调度、数据倾斜和故障恢复实验。

10 参考资料

[1] 林子雨：《大数据基础编程、实验和案例教程》第 3 版，清华大学出版社，2024 年。

[2] Apache Hadoop 3.5.0 Documentation, HDFS Commands Guide 与 MapReduce Tutorial。

[3] 14899 《大数据技术基础（实践）》实践考核方案及实践报告模板，2026 年。

11 提交前检查

材料	状态或操作
实践报告 PDF/Word	已生成；提交前按专业代码_14899_准考证号_姓名重命名
配置文件、输入、输出和日志	已生成并纳入程序包
README.txt	已完成

材料	状态或操作
个人 HDFS 目录	提交前用 STUDENT_ID=准考证号 重新运行
Linux 截图	若考点严格限定 Linux, 应在 Linux 复现后替换图 1
身份信息与承诺书	考生本人填写并签署
知网查重及 AIGC 检测	需考生本人完成并按通知打包